

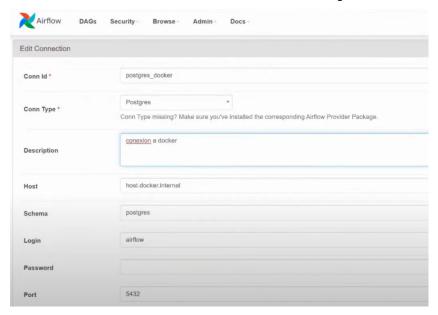
A continuación se puede ver el archivo docker-compose.yaml, en el cual establecemos la configuración de Postgres.

Iniciamos con docker-compose, apoyándonos en el comando up airflow-init.

Luego iniciamos los containers.

```
| Started | Star
```

Airflow permite realizar conexiones a diferentes servicios de la nube, para los distintos proveedores. En este caso debemos establecer la conexión con Postgres.



Utilizamos docker build para construir la imagen.

Se corre nuevamente el webserver y scheduler con la nueva versión extending_airflow:latest202309

```
$ docker-compose up -d --no-deps --build airflow-webserver airflow-scheduler-
time="2023-09-14T11:27:49-06:00" level-warning msg="The \"AIRFLOM_UDD\" variable is not set. Defaulting to a blank string."

[*] Running 2/2

Vontainer data-pipeline-airflow-scheduler-1

Started

Started

Started

Stocker ps

COMMAINER ID

IMAGE

COMMAINER ID

IMAGE

COMMAINER ID

STATUS

TOMMAINER ID

Vusr/bin/dumb-init ..."

2/2 seconds ago

4/2 seconds ago

1/2 seconds (health: starting)

1/2 p 2 seconds (health: starting)

1/2 p 2 seconds (health: starting)

1/2 p 3 sminutes (healthy)

8880/tcp

data-pipeline-airflow-scheduler-1

data-pipeline-airflow-webserver-1

3880/tcp

data-pipeline-airflow-webserver-1

1/2 seconds ago

1/2 p 3 sminutes (healthy)

8880/tcp

data-pipeline-airflow-webserver-1

data-pipeline-airflow-webserver-1

data-pipeline-airflow-webserver-1

data-pipeline-airflow-webserver-1

data-pipeline-airflow-webserver-1

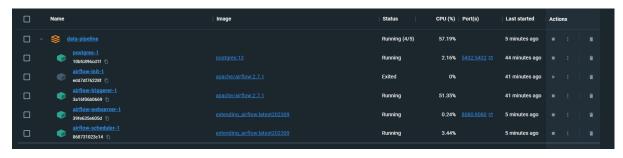
data-pipeline-airflow-webserver-1

data-pipeline-airflow-webserver-1

data-pipeline-airflow-bignerer-1

data-pipeline-postgres-1
```

Ya se pueden ver las imágenes actualizadas en nuestro Docker Desktop.



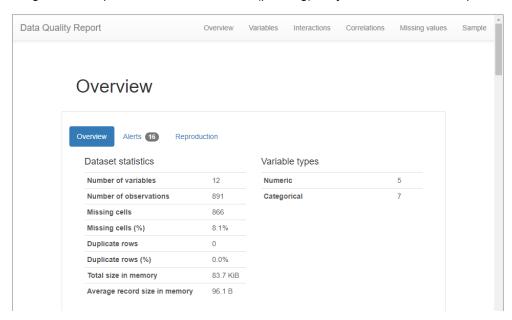
Ingresar a la terminal del scheduler, con la ayuda del Container ID.

```
jhon.edwar.b.salazar@C11-SFI4XGGFG32 MINGW64 ~/Documents/data-pipeline $ docker exec -it 868731023c14 bash airflow@868731023c14:/opt/airflow$
```

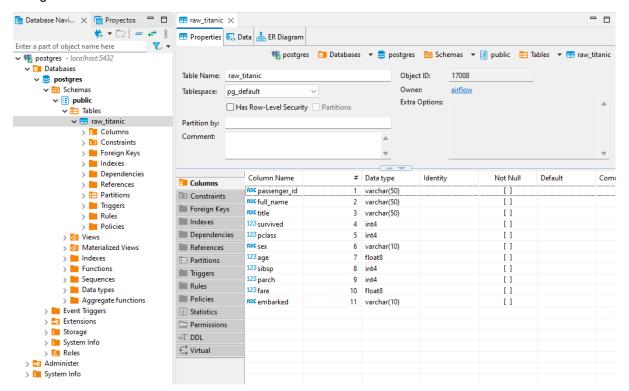
Realizamos el test a la tarea relacionada con descargar el archivo csv. El mensaje "Marking task as SUCCESS" nos deja saber que se ejecutó correctamente.

```
airflow@868731023c14:/opt/airflow/dags$ airflow tasks test dag_webinar descargar_csv 2023-01-01
[2023-09-14117:08:21.578+0000] {dagbag.py:539} INFO - Filling up the DagBag from /opt/***/dags
nstance: dag_webinar.descargar_csv _*** temporary_run_2023-09-14117:08:26.295+0000] {taskinstance.py:1157} INFO - Dependencies all met for dep_context-requeueable deps ti=<TaskInstance: dag_webinar.descargar_csv _****_temporary_run_2023-09-14117:08:26.295+0000] {taskinstance.py:1157} INFO - Dependencies all met for dep_context-requeueable deps ti=<TaskInstance: dag_webinar.descargar_csv _****_temporary_run_2023-09-14117:08:26.296+0000] {taskinstance.py:1159} INFO - Starting attempt 1 of 3
[2023-09-14117:08:26.296+0000] {taskinstance.py:1428} WARNING - cannot record queued_duration for task descargar_csv because previous state change time has not been saved [2023-09-14117:08:26.296+0000] {taskinstance.py:1428} WARNING - cannot record queued_duration for task descargar_csv on 2023-09-10-09:000:00+000:00+000:00
[2023-09-14117:08:26.701+0000] {taskinstance.py:1300} INFO - Exporting env vars: AIRFLOW_CIX_DAG_OWNER='Jhon' AIRFLOW_CIX_DAG_ID='dag_webinar' AIRFLOW_CIX_TASK_ID='descargar_csv' AIRFLOW_CIX_EXCUTION_DATE-'2023-01-01100:00:00+000-00' AIRFLOW_CIX_DAG_ID='dag_webinar' AIRFLOW_CIX_DAG_ID='dag_webinar' AIRFLOW_CIX_DAG_ID='-**_temporary_run_2023-09-14117:08:26.765+0000] {subprocess.py:03} INFO - Running command: ['/bin/bash', '-c', 'curl -k -o /opt/***/dags/data/titanic.csv https://raw.githubusercontent.com/rom/gang/webinar/main/titanic.csv']
[2023-09-14117:08:26.763+0000] {subprocess.py:93} INFO - Marning command: ['/bin/bash', '-c', 'curl -k -o /opt/***/dags/data/titanic.csv https://raw.githubusercontent.com/rom/gang/webinar/main/titanic.csv']
[2023-09-14117:08:26.763+0000] {subprocess.py:93} INFO - Marning task as SUCCESS. dag_id=dag_webinar, task_id=descargar_csv, execution_date=202301017000000, start_date -, end_date=202309141170827
```

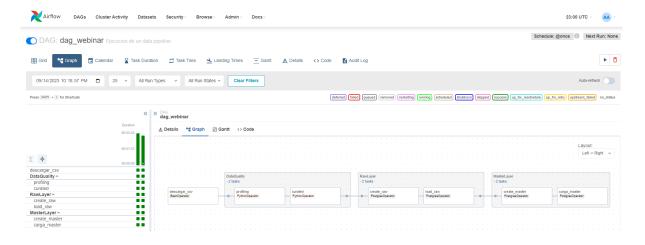
Se genera el reporte de calidad de datos (profiling) al ejecutar la tarea correspondiente.



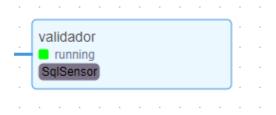
Luego de hacer una limpieza de datos a través de nuestra task *curated*, se realiza la conexión con Postgres.



Se crea una tabla de BD a través de una task del workflow y se cargan los datos con ayuda del archivo sgl creado anteriormente. El workflow queda de la siguiente manera.



Luego de correr el workflow, seleccionamos la opción de *clear task* del validador que realiza un conteo de los registros del día.



GCP Composer - Revisar servicio ya que es económico en cuanto a oferta Cloud (aprox. \$2USD por día)